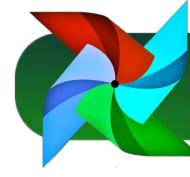
Fundamentos de Apache Airflow

Eric Bellet







Prerrequisitos para el curso



Python intermedio



Docker básico



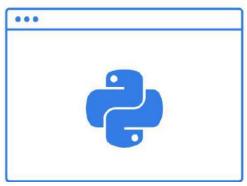
Línea de comandos básico

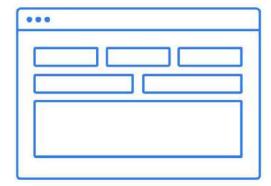
¿Qué es Airflow?



Airflow es una plataforma creada por la comunidad para crear, programar y supervisar flujos de trabajo de forma programada.









Breve historia



Maxime Beauchemin



Airflow was released on October, 2014.

Airflow was made open source on March, 2016.

Airflow was made a top-level Apache
Software
Foundation on
January, 2019.

Airflow 2.0

was released on
December 17th,
2020.

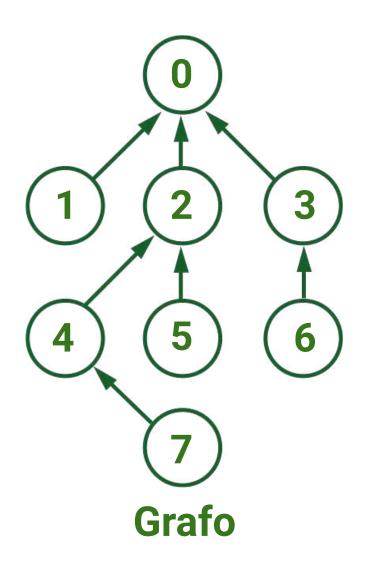
¿Para qué sirve Airflow?



Terminologías

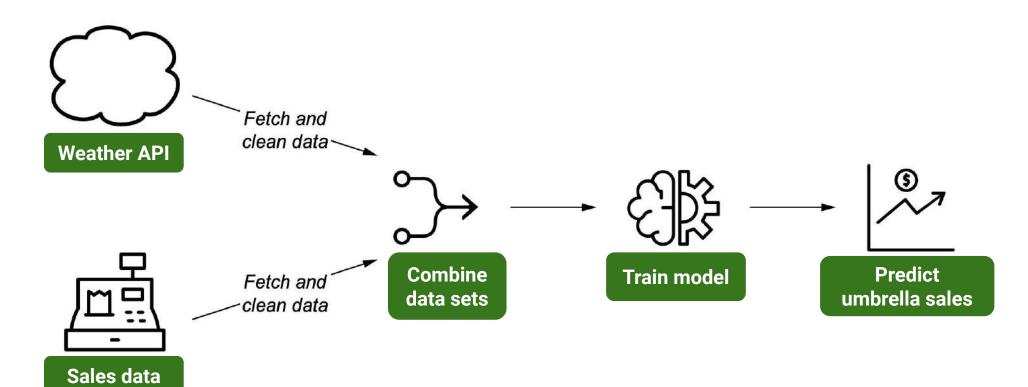
Flujos de datos

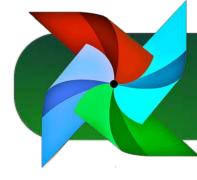
==
Workflow
==
Data pipelines
==
Pipelines de datos



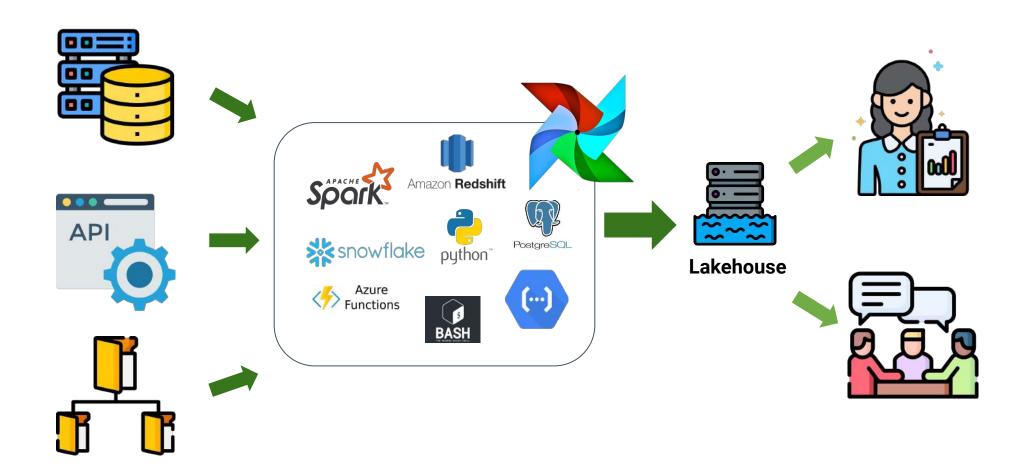


¿Para qué sirve Airflow?



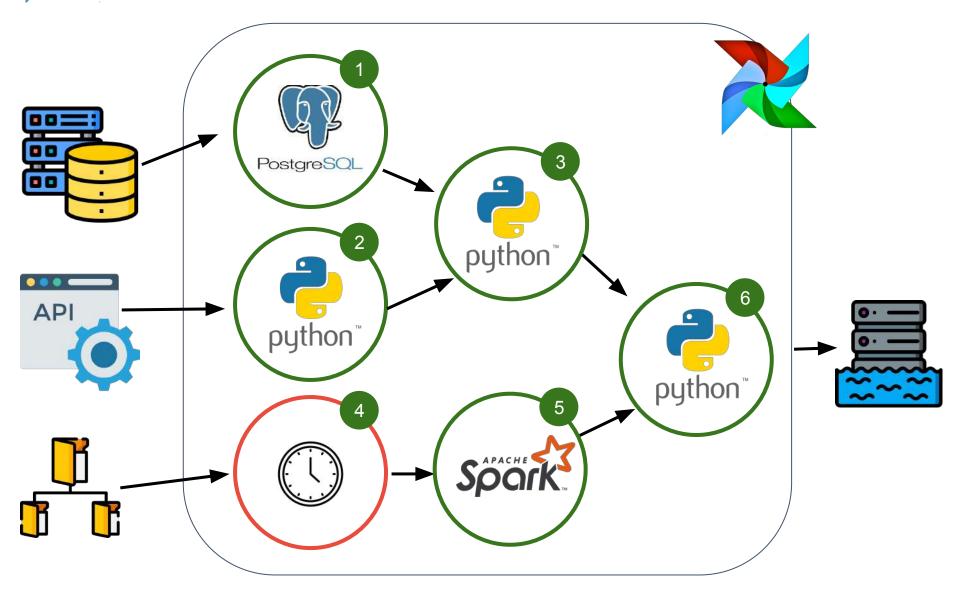


¿Para qué sirve Airflow?





Representación: grafo



¿Por qué usar Airflow?





DAGs

Security

Browse

Admin

Docs

21:11 UTC -

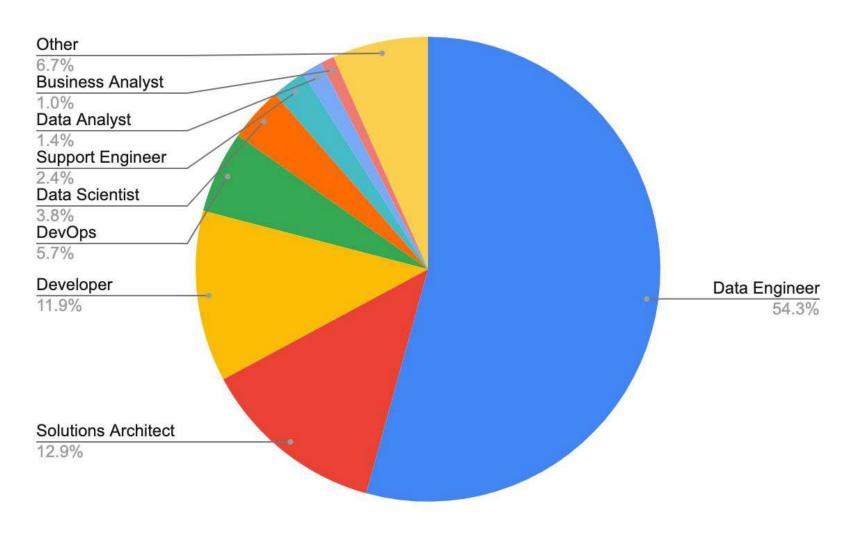


DAGs

All 26 Active 10 Paused 16	Paused 16				Search DAGs			
① DAG	Owner I	Runs 🕕	Schedule	Last Run 🕦	Recent T	asks 🕦	Actions	Links
example_bash_operator example example2	airflow (2	00***	2020-10-26, 21:08:11	0] 000000000	▶ C	···
example_branch_dop_operator_v3	airflow		*/1 * * * *				▶ C	···
example_branch_operator example example2	airflow	000	@daily	2020-10-23, 14:09:17 (000		► C	···
example_complex example example2 example3	airflow (000	None	2020-10-26, 21:08:04	37		▶ C	<u> </u>
example_external_task_marker_child	airflow	\bigcirc	None	2020-10-26, 21:07:33] 0000000	▶ C	<u></u>
example_external_task_marker_parent	airflow	000	None	2020-10-26, 21:08:34	00		▶ C	<u> </u>
example_kubernetes_executor example example2	airflow		None				▶ C	<u> </u>
example_kubernetes_executor_config	airflow	000	None	2020-10-26, 21:07:40		000000	▶ C	···
example_nested_branch_dag	airflow	000	@daily	2020-10-26, 21:07:37] 0000000	▶ C	<u></u>
example_passing_params_via_test_command example	airflow		*/1 * * * *				▶ C	···

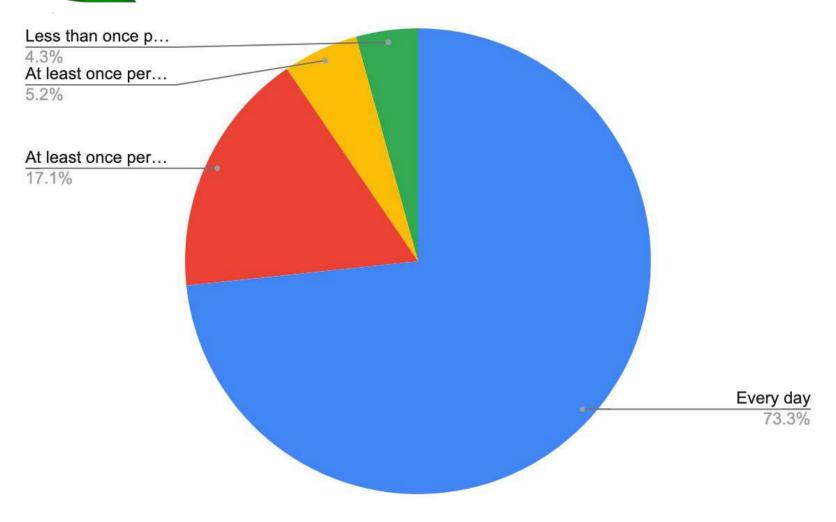


¿Qué perfiles suelen usar Airflow?



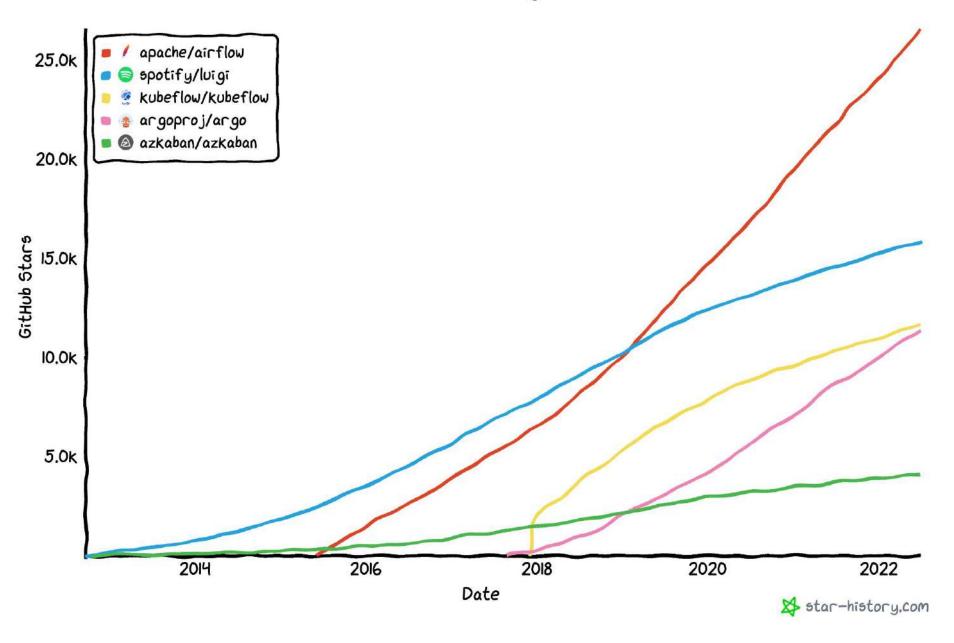
https://airflow.apache.org/blog/airflow-survey-2022/

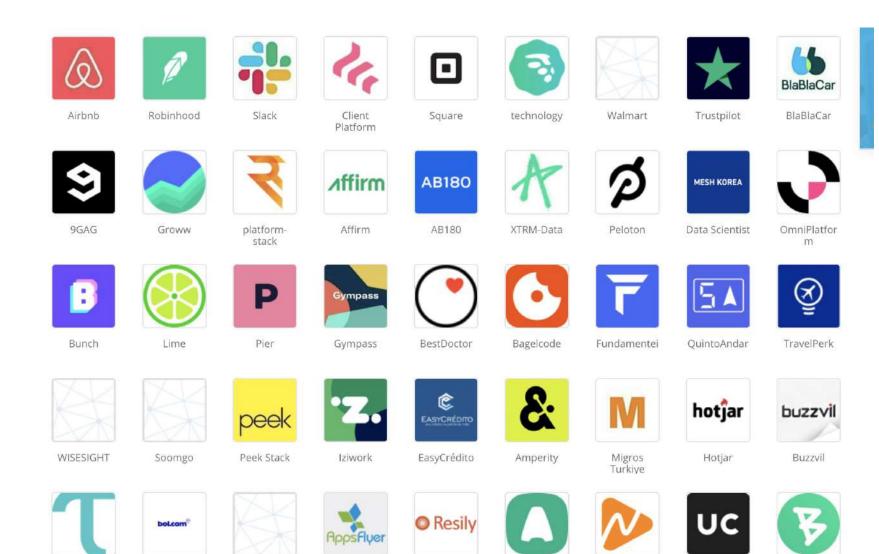




https://airflow.apache.org/blog/airflow-survey-2022/

Star History





resily

Aircall

COMPANIES WE TRACK USING APACHE AIRFLOW

Urban

Company



typecast-

backend

+30.34%

Banksalad

https://stackshare.io/airflow https://discovery.hgdata.com/product/apache-airflow

AppsFlyer

Seguoia

Consulting ...

bol.com

Tigets

Resumen

Resumen

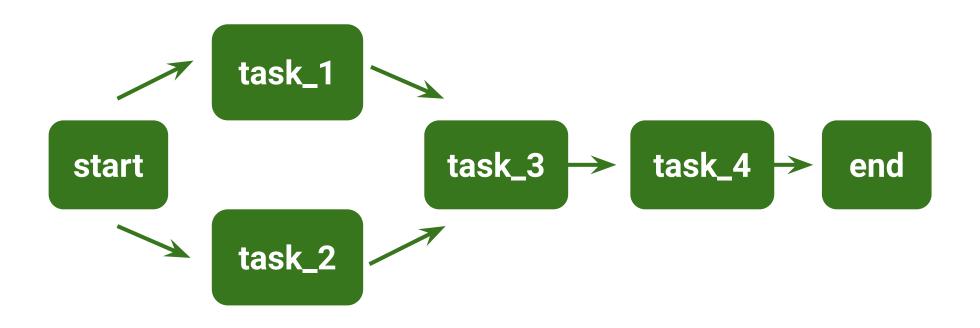
- 1. Desarrollar "workflows" mediante Python.
- 2. Orquestar procesos.
- 3. Monitorear ejecuciones.
- 4. Una herramienta muy usada.
- 5. Un "job scheduler" con esteroides (CRON ++).

Conceptos básicos

DAG



Flujo de trabajo (workflow)





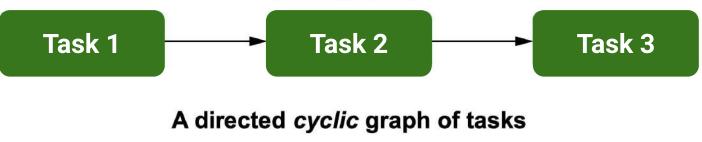
DAG (Directed Acyclic Graph)

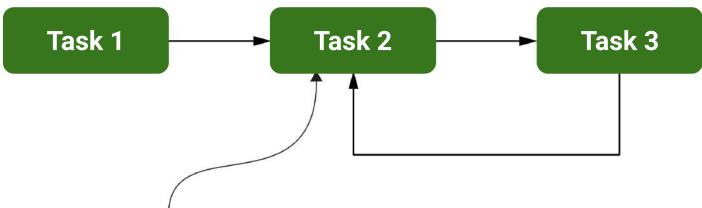




DAG (Directed Acyclic Graph)

A directed acyclic graph (DAG) of tasks



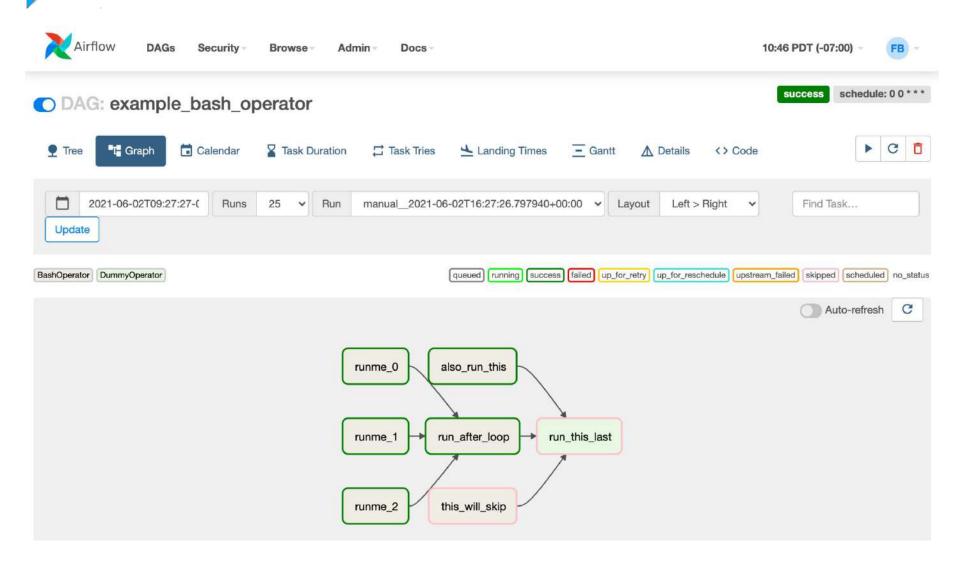


Task 2 will never be able to execute, due to its dependency on task 3, which in turn depends on task 2.

```
from airflow import DAG
with DAG(
    'tutorial',
    default_args={
        'depends_on_past': False,
        'email': ['airflow@example.com'],
        'email_on_failure': False,
        'email_on_retry': False,
        'retries<u>': 1,</u>
        'retry_delay': timedelta(minutes=5)
    description='A simple tutorial DAG',
    schedule_interval=timedelta(days=1),
    start_date=datetime(2021, 1, 1),
    catchup=False,
    tags=['example'],
  as dag:
```



DAG (Directed Acyclic Graph)



Tasks y Operators





Existen 3 tipos básicos de tasks:

- 1. Operators
- 2. Sensors
- 3. TaskFlow-decorated @task



Operators





BashOperator

executes a bash command.

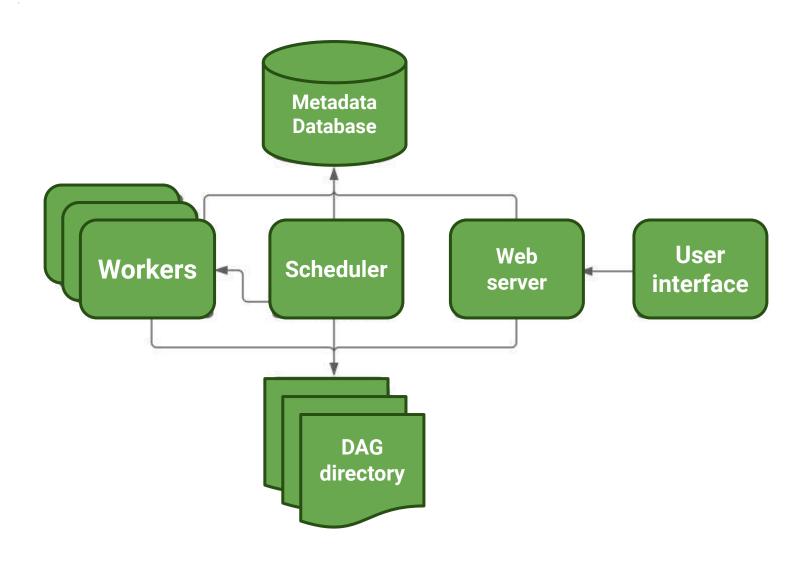
Python0perator calls an arbitrary

Python function.

```
from airflow.operators.bash import BashOperator
t1 = BashOperator(
        task_id='print_hello_bash',
        bash_command='echo "Hello world!"',
from airflow.operators.python import PythonOperator
def print_hello():
    print('Hello world!')
t2 = PythonOperator(
    task_id='print_hello_python',
    python_callable=print_hello
```

Scheduler





Resumen

Resumen

- 1. Un flujo de trabajo se representa como un **DAG**.
- 2. Un **task** es un componente interno para ejecutar operaciones.
- 3. Un **operator** representa una única unidad de trabajo.
- 4. El **scheduler** se encarga de ejecutar los DAGs en intervalos de tiempo.

Instalación y configuración



Instalación

- Using released sources.
- Using PyPl.
- Using Production Docker Images.
- Using Official Airflow Helm Chart.
- Using Managed Airflow Services.
- Using 3rd-party images, charts, deployments.

https://airflow.apache.org/docs/apache-airflow/stable/installation/index.html



Instalación usando Docker

docker-compose.yaml

To deploy Airflow on Docker Compose, you should fetch docker-compose.yaml.

curl -Lf0 'https://airflow.apache.org/docs/apache-airflow/2.3.3/docker-compose.yaml'

Configuraciones



Referencia de configuración

Las configuraciones disponibles de Airflow se pueden establecer en el archivo **airflow.cfg** o mediante variables de entorno.

https://airflow.apache.org/docs/apache-airflow/stable/configurations-ref.html

Quiz

Variables y conexiones

Configurando variables

Configurando conexiones

```
from airflow.providers.postgres.operators.postgres import PostgresOperator

populate_pet_table = PostgresOperator(
    task_id="populate_pet_table",
    postgres_conn_id="my_postgres_conn",
    sql="sql/pet_schema.sql",
)
```

Implementando un DAG



Declarando un DAG

Standard constructor



Declarando un DAG

Context manager

```
with DAG(
    "my_dag_name", start_date=pendulum.datetime(2021, 1, 1, tz="UTC"),
    schedule_interval="@daily", catchup=False
) as dag:
    op = EmptyOperator(task_id="task")
```



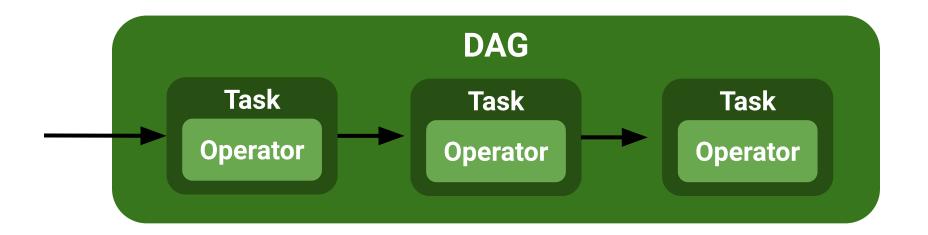
Declarando un DAG

@dag decorator

Bash operator



Declarando un operador



https://airflow.apache.org/docs/apache-airflow/stable/concepts/operators.html

Python operator



Python operator

```
from airflow.operators.python import PythonOperator

def print_test():
    return 'Test'

t2 = PythonOperator(
    task_id='print_test',
    python_callable=print_test
)
```

Dependencias entre tareas

Definiendo dependencias entre tareas

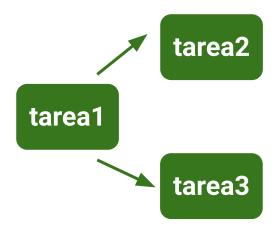
```
# Opción 1:
tarea1.set_downstream(tarea2)
tarea2.set_downstream(tarea3)
# Opción 2: bitshift operators
tarea1 >> tarea >> tarea3
```





Definiendo dependencias entre tareas

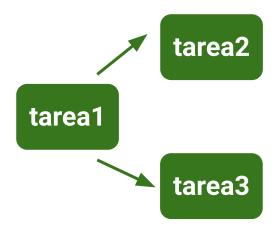
```
# Opción 1:
tarea1.set_downstream([tarea2, tarea3])
# Opción 2: bitshift operators
tarea1 >> [tarea2, tarea3]
```





Definiendo dependencias entre tareas

```
# Opción 1:
tarea1.set_upstream([tarea2, tarea3])
# Opción 2: bitshift operators
tarea1 << [tarea2, tarea3]</pre>
```



Custom operator



Creando un custom operator

```
from airflow.models.baseoperator import BaseOperator
class HelloOperator(BaseOperator):
    def __init__(self, name: str, **kwargs) -> None:
        super().__init__(**kwargs)
        self.name = name
    def execute(self, context):
        message = f"Hello {self.name}"
        print(message)
        return message
```

https://airflow.apache.org/docs/apache-airflow/stable/howto/custom-operator.html

Resumen

Resumen

- 1. Implementar un **DAG.**
- 2. Implementar un operator.
- 3. Definir **dependencias** entre las tareas.
- 4. Implementar un custom operator.

Orquestar y monitorizar procesos



Orquestando un DAG

preset	meaning	cron
None	Don't schedule, use for exclusively "externally triggered" DAGs	
@once	Schedule once and only once	
@hourly	Run once an hour at the beginning of the hour	0 * * *
@daily	Run once a day at midnight	00***
@weekly	Run once a week at midnight on Sunday morning	00 * * 0
@monthly	Run once a month at midnight of the first day of the month	001**
@quarterly	Run once a quarter at midnight on the first day	0 0 1 */3 *
@yearly	Run once a year at midnight of January 1	0011*

https://airflow.apache.org/docs/apache-airflow/stable/dag-run.html?highlight=cron

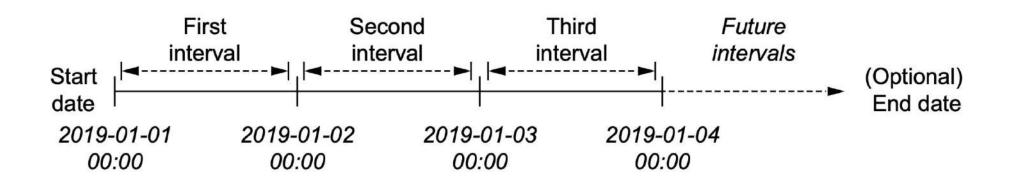


Orquestando un DAG

https://crontab.guru/



Orquestando un DAG



Monitoring



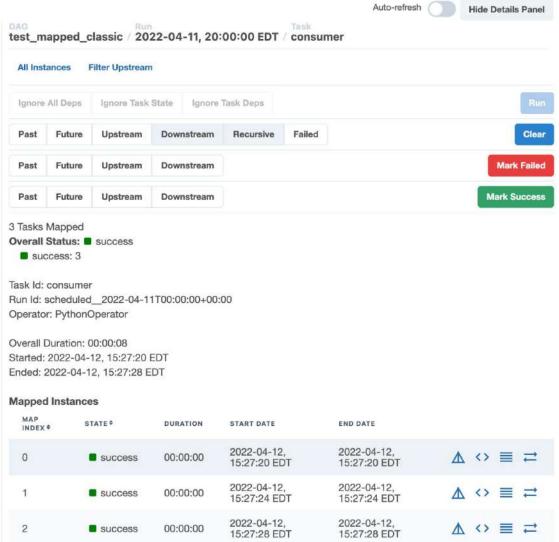
Ejemplos de fallos

- 1. La API a la queremos acceder esta caída.
- 2. Tenemos un error de lógica en nuestro código.
- 3. Algún proceso del que dependemos se ejecutó incorrectamente.
- 4. Se ha borrado una tabla de una base de datos.
- 5. Un sensor llegó al timeout.



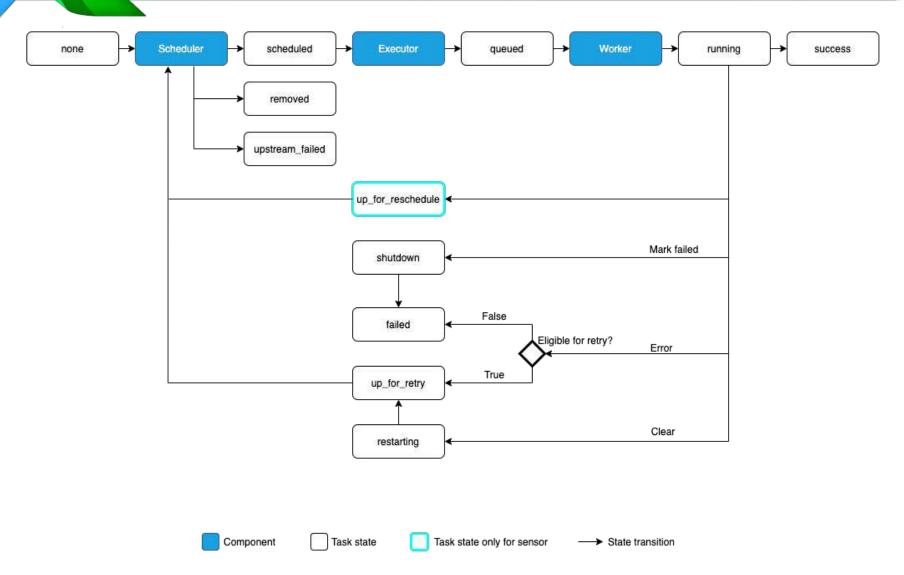
Monitoreando un DAG





Task actions

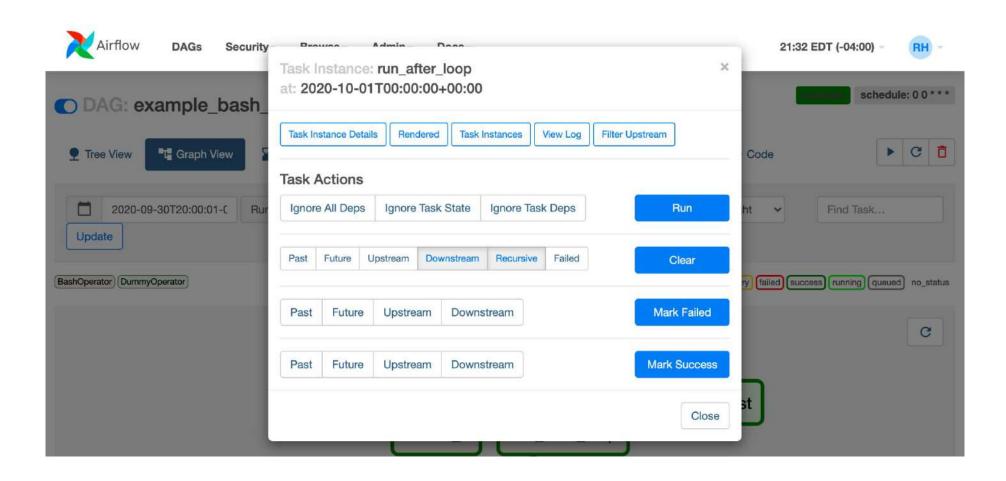
Estados de los tasks



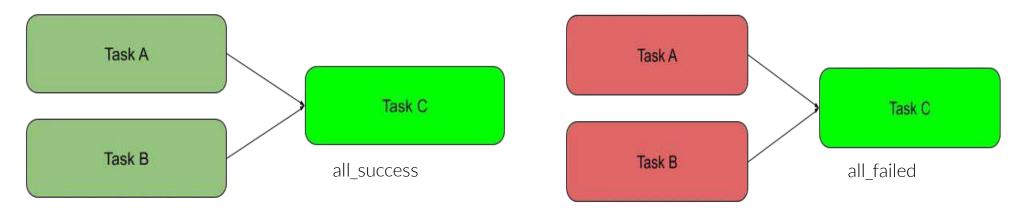
https://airflow.apache.org/docs/apache-airflow/stable/concepts/tasks.html



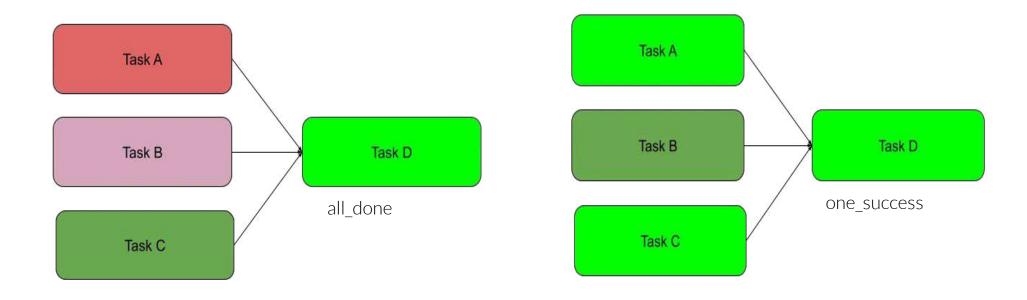
Task actions

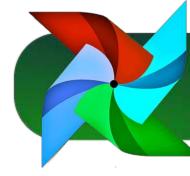


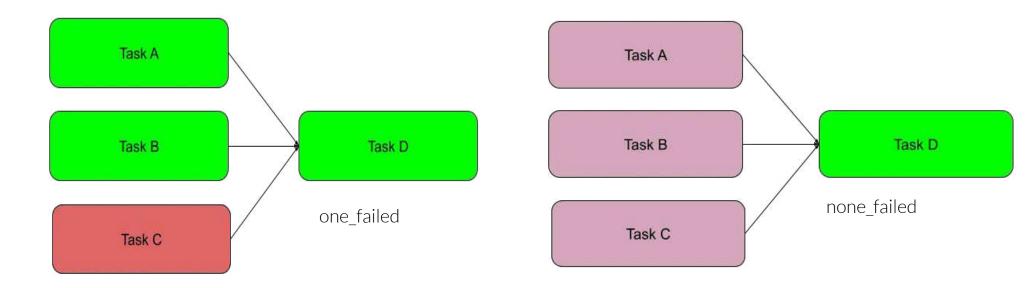












Resumen

Resumen

- 1. Podemos orquestar usando la sintaxis de Airflow o de Cron.
- 2. Podemos monitorear nuestros procesos.
- 3. Podemos realizar backfills.
- 4. Los tasks pueden pasar por varios estados.

Sensores



¿Qué son los sensores?

Los sensores son un tipo especial de operadores que están diseñados para hacer exactamente una cosa: **esperar a que ocurra algo.**







https://airflow.apache.org/docs/apache-airflow/stable/concepts/sensors.html



Tipos de sensores

- ExternalTaskSensor
- FileSensor
- HttpSensor
- S3KeySensor
- SqlSensor

https://airflow.apache.org/docs/apache-airflow/stable/_api/airflow/sensors/index.html?highlight=sensors#module-airflow.sensors

Templates con Jinja



¿Qué son los templates con Jinja?

- Nos permiten sustituir información durante la ejecución.
- Nos dan flexibilidad cuando definimos tareas.
- Son creados usando el "templating language" Jinja.

XComs



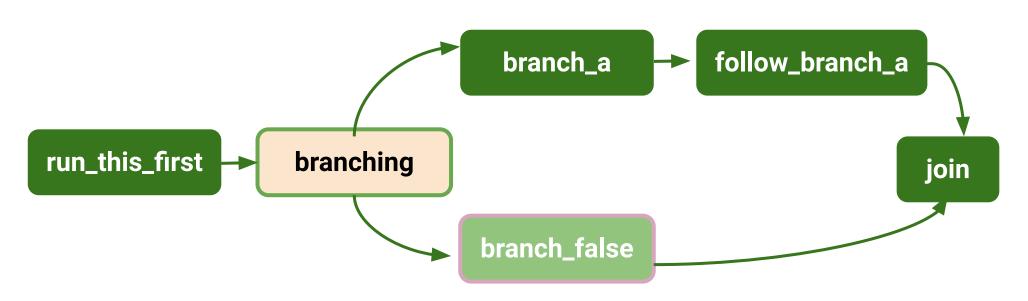
¿Qué son los XComs?

Los XComs (abreviatura de "cross-communications") son un mecanismo que permite que las tasks se comuniquen entre sí, ya que por defecto estas están totalmente aisladas y pueden estar ejecutándose en máquinas totalmente diferentes.

BranchPythonOperator



BranchPythonOperator



Proyecto

Platzi explora el espacio

Primera **EdTech** de la historia en lanzar un satélite al espacio incursionando al mismo tiempo en la exploración espacial.



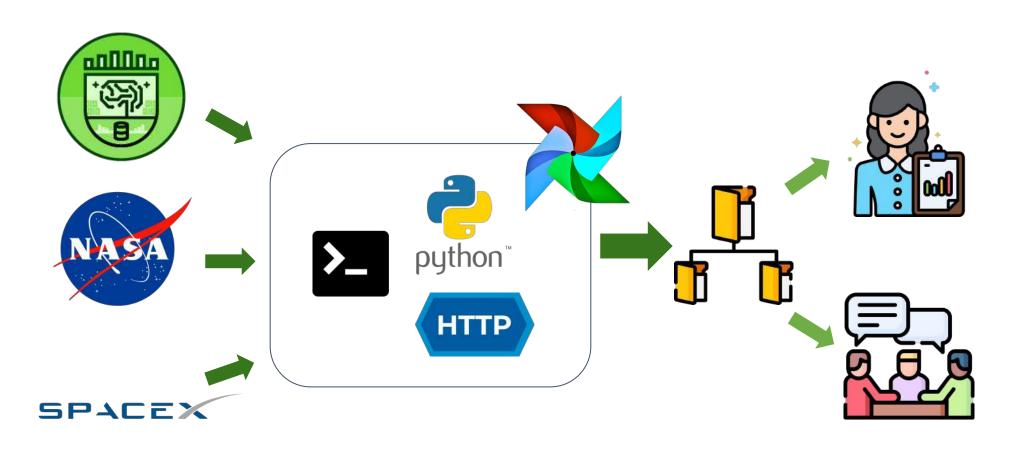
Objetivos

Los equipos de analistas y marketing de Platzi necesitan datos de los estudiantes que han accedido al satélite e información del historial de eventos de SpaceX, por lo tanto necesitamos que nos ayudes a ejecutar las siguientes tareas.

- Esperar a que la NASA nos dé autorización para acceder a los datos del satélite.
- Recolectar datos del satélite y dejarlos en un fichero.
- 3. Recolectar datos de la API de SpaceX y dejarlos en un fichero.
- Enviar un mensaje a los equipos de que los datos finales están disponibles.

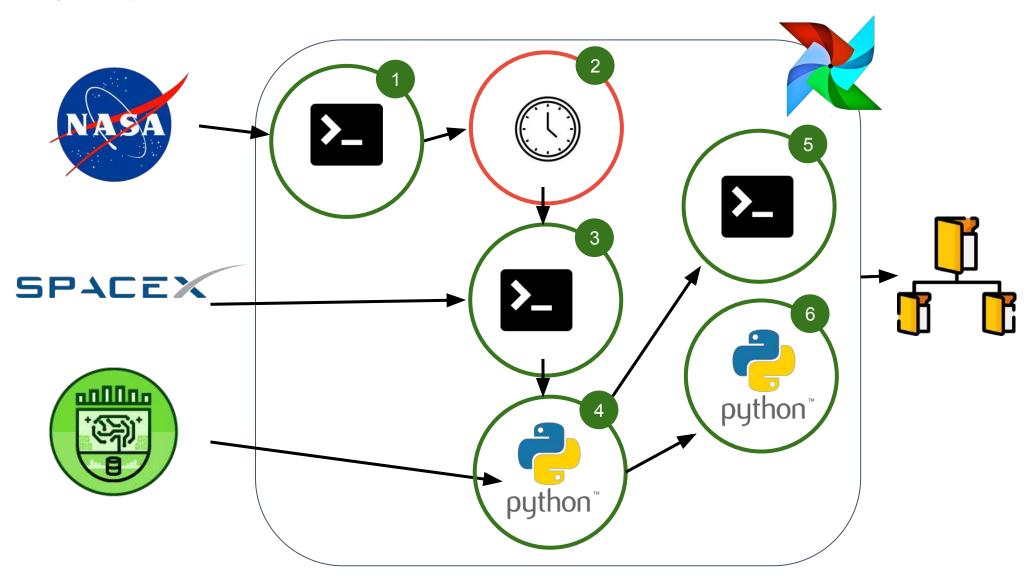


Ejemplo: workflow





Ejemplo: grafo



Cierre del curso



Cierre del curso

- 1. ¿Qué es Airflow? ¿Para qué y por qué utilizarlo?
- 2. Instalación y configuraciones.
- 3. Creación de DAGs.
- 4. Utilización de operadores.
- 5. Orquestación y monitorización.
- 6. Sensores, templates, Xcoms y BranchPythonOperator.